

파이썬을 활용한 데이터 분석 - 주차별 과제(One Page Reporting)

과제 주차	학과	학번	이름
(10) 주차	기계항공공학부	20210809	이종빈

주의사항:

- 한페이지를 초과할 경우 0점 처리 되니 반드시 한 장으로 작성
- 손필기 도구(펜 디바이스 또는 펜)를 사용하여 작성한 경우에만 점수 부여

머신러닝에서 스케일링이 필요한 이유는 서로 다른 특성간의 스케일은 원리 서기기 위해서이다.
예를 들어 값의 범위가 100만 특성과 1000만 특성이 있으면 거시기본 난괴리는 유클리드 거리를 주로 사용하기 때문에 범위가 1000만 특성이 더욱 영향력을 가하게 되어 학습이 균형 있게 이루어 지지 않게 된다.

Min-MaxScaler

최대최소 스케일링은 특성의 최대값을 1로 최소값을 0으로 하는 스케일링 방법이다.

np.array x에 대해

$$x_scaled = (x - x.min()) / (x.max() - x.min())$$

을 실행하면 Min-MaxScaler 와 동일한 결과를 가진다.

StandardScaler

특성이 데이터 값에서 그 특성의 평균을 빼고 표준편차를 나누는 표준화를 수행한다

np.array x에 대해

$$x_scaled = (x - x.mean()) / x.std(ddof=0)$$

을 수행하면 동일한 결과를 얻는다.

MinMaxScaling의 경우

인공신경망 모델은 사용함에 주로 사용된다.

Standard Scaling의 경우

최대최소 스케일링의 경우 최대값이나 최소값이 이상적인 경우 같이 아니 범위로 클리어 데이터의 분포가 왜곡되는 경우가 발생한다. Ex) [0, 10, 20, 1000000] -> [0, 1e-11, 2e-11, 1]

평균과 분산이 이상치에 영향을 받지만 최대최소 스케일링 보다는 상대적으로 강건하므로

스케일링이 필요한 상황에 Standard Scaling을 적용할 수 있다.